


# Day 09

## 深度學習與電腦視覺 學習馬拉松

cupay 陪跑專家：楊鎮銘



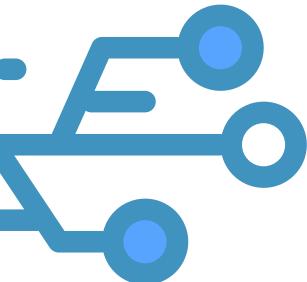
# 基礎影像處理

## SIFT 的概念與實作



# 重要知識點

- 了解 SIFT 是基於甚麼觀念進行改進
- 了解 SIFT 演算法的物理意義




# 何謂特徵？



前面我們介紹了 Filter 的操作，了解計算圖片的導數就會取得邊緣  
在電腦視覺中我們也可以把這個過程稱為「抽取特徵」

所謂特徵，可以非常直覺的解釋為「圖片中最特別的地方」  
可以是邊緣，輪廓，紋理等資訊



# SIFT 特徵 - 概念




本章節要介紹的 SIFT 就是其中一種表徵 (appearance feature)

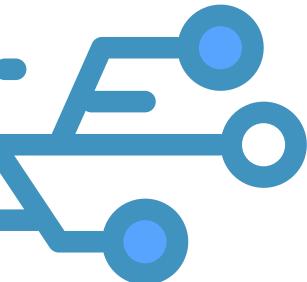
基於局部的外觀特徵，進一步考慮到圖片特徵的狀況

- 縮放不變性，旋轉不變性
- 光線與雜訊容忍度高

在 SIFT 演算法中可以了解到如何做關鍵點偵測  
並如何抽出 SIFT 特徵來敘述關鍵點

右圖：示意該圖片的 SIFT 特徵







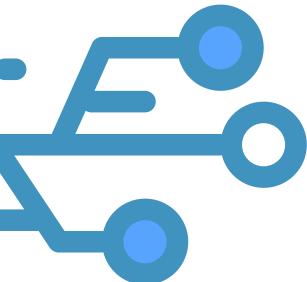
# SIFT 特徵 - 尺度不變性



SIFT 主要考慮到的問題之一是尺度

以 corner detector (e.g. [Harris](#)) 為例，Filter 可以偵測到範圍以內的角落點，但是同樣的 pattern 放大後以同樣的 Filter 去偵測就會失敗





# SIFT 特徵 - 尺度空間極值偵測




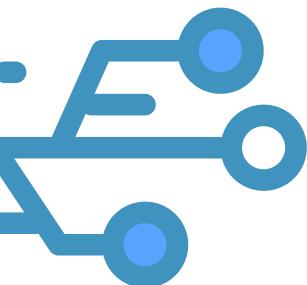
SIFT 會基於邊緣檢測抽取特徵，但不是使用前面提過的 Sobel 概念上是 LoG 但是考慮到計算量使用 DoG 做邊緣檢測

- Laplacian of Gaussian (LoG)
  - \* 先對圖片做 Gaussian Blur 再算二階導數取得邊緣
- Difference of Gaussian (DoG)
  - \* 圖片經過不同程度的縮放後計算出不同程度的 Gaussian Blur 最後合併得到一個 Gaussian Pyramid，其差值即為 DoG
  - \* 結果可以視為 LoG 的約略值 (沒有做二階導數)



這邊討論的特徵主要是物體的邊緣  
而二階導數是個適合的工具來找出邊緣，因此這邊才會以此討論 LoG 與 DoG







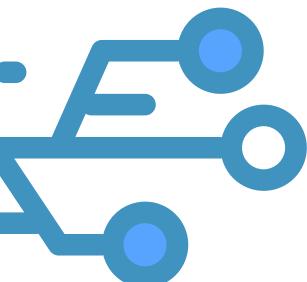
# SIFT 特徵 - 尺度空間極值偵測 (DoG 尺度)



DoG 詳解 (如右圖所示)

- 圖片的一種 scale 稱為一個 octave
- 每種 scale 的圖片經過不同程度的 Gaussian Blur 在計算其差值
- 最後會得到右圖最後的 DoG (Gaussian Pyramid)







# SIFT 特徵 - 尺度空間極值偵測 (極值偵測)

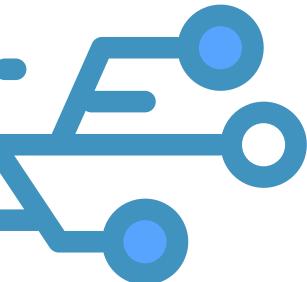


前面提到的 DoG 影像包含多種尺度  
接著要針對每個 pixel 判斷是否為極值  
判斷範圍  $8+18 = 26$

- 自己本身周遭的 8 個 pixel
- 同一個 scale 圖片但不同模糊尺度  
相鄰位置共  $9*2=18$  個 pixel

假如該 pixel 為判斷範圍內的最大 / 最小值  
則將其設為有興趣的關鍵點





# SIFT 特徵 - 關鍵點定位




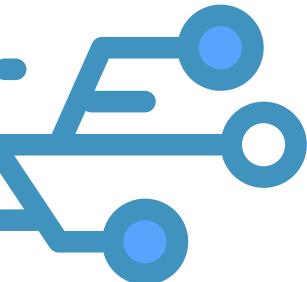
經過多尺度極值偵測之後，會得到許多候選的關鍵點  
其中也包含許多噪音跟邊的關鍵點  
需要更進一步根據周遭資訊來修正並過濾關鍵點

- 鄰近資料差補
  - \* 主要根據相鄰資訊來修正極值的位置
- 過濾不明顯關鍵點
  - \* 根據計算曲率來判斷是否為不明顯的關鍵點
- 過濾邊緣關鍵點
  - \* 根據計算曲率來判斷是否為不明顯的關鍵點



Note: 這邊包含大量數學推導，不詳細解釋，如果有興趣可以參考最後的 reference







# SIFT 特徵 - 方位定向



前面我們定義並過濾了許多關鍵點，但是關鍵點只有包含尺度跟位置  
SIFT 還想要保有旋轉不變性，因此要給關鍵點定義一個方向

- 以每 10 度為單位計算周圍的梯度值
- 梯度值最大的方向當作是該關鍵點的主要方向






# SIFT 特徵 - 關鍵點描述子




賦與關鍵點位置，尺度，方向確保移動，縮放，旋轉的不變性  
還需要額外建立描述子來確保不同光線跟視角也有不變性

- 描述子會正規化成 128 維的特徵向量
- 以關鍵點周圍  $16 \times 16$  的區域共  $4 \times 4$  的子區域，計算 8 個方向的直方圖，共  $4 \times 4 \times 8 = 128$  維的特徵向量



Note :

每個關鍵點都會產生 128 維的特徵  
而圖片會產生 N 個關鍵點，也就是會產生  $(N, 128)$  維度特徵






如果要透過 OpenCV 使用 SIFT 的話必須要額外安裝擴充的函式庫  
為了避免版本問題，我們會指定安裝版本

```
pip install opencv-contrib-python==3.4.2.16
```

接著才有辦法使用 SIFT 來抽取特徵

```
sift = cv2.xfeatures2d.SIFT_create() # 建立 SIFT 物件  
keypoints = sift.detect(img_gray, None) # 抽取關鍵點  
img_show = cv2.drawKeypoints(img_gray, keypoints, img)
```



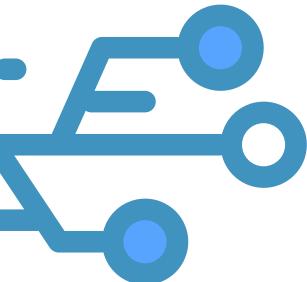
# 知識點 回顧

- 了解 SIFT 演算法的物理意義
  - 從 LoG 變為 DoG 取得多尺度空間
  - 透過極值找候選的關鍵點
  - 透過主曲率過濾關鍵點
  - 透過區域劃分決定方向並正規化成 128 維向量

# 範例

- 實作取得 SIFT 特徵
  - 需要轉成灰階圖片
  - 需要額外安裝 OpenCV 相關套件





# 推薦延伸閱讀



## SIFT特徵提取分析

2012-06-06 22:06:09 Rachel-Zhang 阅读数 534765 文章标签: 角点特征 SIFT 角点检测 更多

版权声明: 本文为博主原创文章, 遵循 CC 4.0 BY-SA 版权协议, 转载请附上原文出处链接和本声明。

本文链接: <https://blog.csdn.net/abcjenifer/article/details/7639681>

SIFT (Scale-invariant feature transform) 是一种检测局部特征的算法, 该算法通过求一幅图中的特征点 (interest points, or corner points) 及其有关 scale 和 orientation 的描述子得到特征并进行图像特征点匹配, 获得了良好效果, 详细解析如下:

### 算法描述

SIFT 特征不只具有尺度不变性, 即使改变旋转角度, 图像亮度或拍摄视角, 仍然能够得到好的检测效果。整个算法分为以下几个部分:

#### 1. 构建尺度空间

这是一个初始化操作, 尺度空间理论目的是模拟图像数据的多尺度特征。

高斯卷积核是实现尺度变换的唯一线性核, 于是一副二维图像的尺度空间定义为:

$$L(x, y, \sigma) = G(x, y, \sigma) * I(x, y)$$

$$G(x, y, \sigma) = \frac{1}{2\pi\sigma^2} e^{-(x^2+y^2)/2\sigma^2}.$$

其中  $G(x, y, \sigma)$  是尺度可变高斯函数

$(x, y)$  是空间坐标, 是尺度坐标。 $\sigma$  大小决定图像的平滑程度, 大尺度对应图像的概貌特征, 小尺度对应图像的细节特征。大的 $\sigma$  值对应粗糙尺度(低分辨率), 反之, 对应精细尺度(高分辨率)。为了有效的在尺度空间检测到稳定的关键点, 提出了高斯差分尺度空间 (DOG scale-space)。利用不同尺度的高斯差分核与图像卷积生成。


$$\begin{aligned} D(x, y, \sigma) &= (G(x, y, k\sigma) - G(x, y, \sigma)) * I(x, y) \\ &= L(x, y, k\sigma) - L(x, y, \sigma). \end{aligned}$$

## SIFT 特徵分析

部落格文章中有針對 SIFT 詳細數學的推導  
[連結](#)

### 基本原理:

角點是一幅影象上最明顯與重要的特徵, 對於一階導數而言, 角點在各個方向的變化是最大的, 而邊緣區域在只是某一個方向有明顯變化。一個直觀的圖示如下:




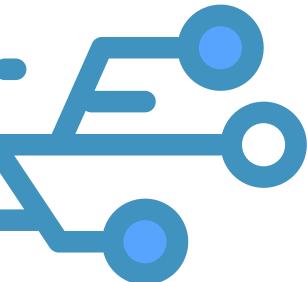
云教程中心

## Harris detectXor

本章在討論尺度不變性時有提到用來偵測角落的 Harris detector, 可以參考這個中文部落格, 裏面包含數學推導

[連結](#)





# 推薦延伸閱讀



## Laplacian/Laplacian of Gaussian



Common Names: Laplacian, Laplacian of Gaussian, LoG, Marr Filter

### Brief Description

The Laplacian is a 2-D [isotropic](#) measure of the 2nd [spatial derivative](#) of an image. The Laplacian of an image highlights regions of rapid intensity change and is therefore often applied to an image that has first been smoothed with something approximating a [Gaussian smoothing filter](#) in order to reduce its sensitivity to noise, and hence the two single graylevel image as input and produces another graylevel image as output.

### How It Works

The Laplacian  $L(x,y)$  of an image with pixel intensity values  $I(x,y)$  is given by:

$$L(x, y) = \frac{\partial^2 I}{\partial x^2} + \frac{\partial^2 I}{\partial y^2}$$

This can be calculated using a [convolution filter](#).

Since the input image is represented as a set of discrete pixels, we have to find a discrete convolution kernel that can approximate the second derivatives in the definition of the

## Laplacian of Gaussian

本章在介紹 DoG 的時候有提到 LoG，有興趣可以參考這個部落格文章，包含數學推導跟一些圖可以幫助理解

[連結](#)

## Math 660: Principal curvatures


Jeff Jauregui

Thursday, October 20, 2011

### Abstract

Our goal is to explain the idea of principal curvatures of surfaces in  $\mathbb{R}^3$  as simply as possible, without referring to the shape operator or covariant derivative. These notes were used in a Riemannian geometry course at UPenn for students who had not previously studied differential geometry of curves and surfaces.

Let's assume we have a surface  $M$  in  $\mathbb{R}^3$  that is given by the graph of a smooth function  $z = f(x, y)$ . Assume that  $M$  passes through the origin,  $p$ , and its tangent plane there is the  $\{z = 0\}$  plane<sup>1</sup>. Let  $N = (0, 0, 1)$ , a unit normal to  $M$  at  $p$ .




Let  $v$  be a unit vector in  $T_p M$ , say  $v = (v_1, v_2, 0)$ . Let  $c$  be the parameterized curve given by slicing  $M$  through the plane spanned by  $v$  and  $N$ :

<sup>1</sup>In general, if  $M$  is any surface in  $\mathbb{R}^3$ , and if  $p \in M$ , then we may apply rigid motions to assume without loss of generality that  $p$  is the origin and  $T_p M$  is the  $\{z = 0\}$  plane. Near  $p$ ,  $M$  is locally a graph  $z = f(x, y)$ .

## 主曲率計算

本章在介紹 DoG 的時候有提到 LoG，有興趣可以參考這個部落格文章，包含數學推導跟一些圖可以幫助理解

[連結](#)



# 解題時間 Let's Crack It



請跳出 PDF 至官網 Sample Code & 作業開始解題